

APRENDIZADO DE MÁQUINA (CIC1205)

Trabalho 2

Prof. Eduardo Bezerra (ebezerra@cefet-rj.br)

CEFET/RJ - Programa de Pós-graduação em Ciência da Computação

Abril/2026

Sumário

1	Engenharia de <i>Features</i> (2 pts)	4
2	Classificação Ordinal Multiclasse (2 pts)	4
3	SHAP Values (2 pts)	6
4	Redução de dimensionalidade (2 pts)	7
5	Predição Conforme (2 pts)	7

Especificação da entrega

1. Você deve produzir um único *notebook* Jupyter contendo as **implementações, os resultados de execução e as análises** referentes a todas as partes deste trabalho.
2. Organize o *notebook* com células de texto em *markdown*, de modo que cada item do trabalho apareça em uma seção claramente identificada e facilmente localizável.
3. Em cada item, apresente não apenas o código, mas também uma explicação objetiva da metodologia adotada, das decisões tomadas e dos resultados obtidos.
4. Sempre que houver etapas de pré-processamento, seleção de atributos, redução de dimensionalidade, escolha de hiperparâmetros ou calibração, tome o cuidado de evitar *data leakage*. Em particular, qualquer transformação aprendida a partir dos dados deve ser ajustada apenas com os dados de treino e, quando cabível, de validação, e só então aplicada ao conjunto de teste.
5. Já é fornecido junto com este enunciado um *notebook* Jupyter para você usar como ponto de partida. Você encontra esse arquivo neste [link](#).
6. O único arquivo a ser submetido é o *notebook* Jupyter. Esse arquivo deve ser obrigatoriamente nomeado com o seguinte padrão: `CIC1205_T2_SEU_NOME_COMPLETO.ipynb`. Exemplo: `CIC1205_T2_EDUARDO_BEZERRA_DA_SILVA.ipynb`.
7. Você deve também elaborar um vídeo de **aproximadamente 15 minutos**, no qual explique os aspectos mais importantes de cada parte do trabalho, demonstre a execução do *notebook* e apresente uma análise dos resultados. O link para acesso a esse vídeo deve estar contido na primeira célula de texto do *notebook*.
8. Cuide para que a qualidade audiovisual do vídeo esteja adequada para avaliação.
9. A entrega deve ser realizada pela plataforma MS Teams, até a data estabelecida. Trabalhos entregues com atraso sofrerão desconto de 20% por dia de atraso.
10. Este trabalho é individual. Você é livre para discutir ideias com colegas, mas deve produzir e redigir sua solução individualmente. Eventuais cópias, totais ou parciais, serão penalizadas com nota zero.

1 Engenharia de *Features* (2 pts)

O conjunto de dados **diamonds** contém informações sobre mais de 50.000 diamantes, incluindo características como quilate, corte, cor, pureza e preço. Este item visa avaliar sua capacidade de transformar variáveis existentes e criar novas *features* potencialmente úteis para um problema de regressão.

Tarefa

Realize engenharia de *features* no conjunto **diamonds**, observando as instruções abaixo:

1. **Criação de novas features:** crie **pelo menos duas novas variáveis** derivadas das variáveis originais. Alguns exemplos possíveis são:
 - combinação de variáveis (por exemplo, volume do diamante a partir de **x**, **y** e **z**);
 - codificação ordinal de variáveis categóricas como **cut**, **color** e **clarity**;
 - transformações logarítmicas ou polinomiais de variáveis contínuas;
 - criação de variáveis binárias ou categóricas a partir de limiares relevantes.
2. **Justificativa:** para cada nova *feature*, explique claramente:
 - como ela foi construída;
 - por que essa transformação faz sentido do ponto de vista do problema;
 - de que forma ela pode contribuir para a predição do preço.
3. **Análise exploratória:** inclua **pelo menos dois gráficos** que ajudem a investigar a relação entre suas novas *features* e o preço do diamante.
4. **Avaliação preditiva:** treine um modelo de regressão simples (usando, por exemplo, **LinearRegression** ou **GradientBoostingRegressor**) em duas versões do conjunto de dados: uma contendo apenas as *features* originais e outra incluindo também as *features* criadas. Compare o desempenho dos dois modelos no conjunto de teste usando ao menos uma métrica adequada (por exemplo, RMSE ou R^2). O objetivo não é obter o melhor modelo possível, mas sim verificar empiricamente se as novas *features* agregam valor preditivo.
5. **Discussão:** com base nos gráficos e nos resultados da avaliação preditiva, discuta se as novas *features* parecem ou não promissoras para um modelo de regressão.
6. **Entrega:** apresente o código, os gráficos e as justificativas no *notebook* e no vídeo explicativo.

2 Classificação Ordinal Multiclasse (2 pts)

Neste item, você deve revisitar o arquivo **A652.pickle**. No Trabalho 1, o problema foi tratado como uma tarefa de classificação binária. Agora, você deve tratá-lo como uma tarefa de **classificação ordinal multiclasse**. Em problemas de classificação ordinal, as classes possuem

uma ordem natural. Neste item, você deve implementar a abordagem descrita no artigo [Simple Approach to Ordinal Classification](#) para construir um classificador ordinal multiclasse.

A essência da abordagem consiste em decompor o problema de K classes em $K-1$ problemas binários, onde o k -ésimo classificador aprende a distinguir as classes com $\text{rank} \leq k$ das classes com $\text{rank} > k$. A predição final é obtida a partir da combinação das saídas desses classificadores binários. Você deve **implementar essa lógica diretamente**, sem depender de bibliotecas externas que já forneçam o método pronto. A página do [OrdinalClassifier no GitHub](#) pode ser consultada como referência conceitual, mas o código submetido deve ser de sua autoria.

Para isso, discretize os valores de precipitação (em mm/h) em cinco classes, conforme o mapeamento abaixo:

- $0 \rightarrow \text{NONE}$
- $(0, 5] \rightarrow \text{WEAK}$
- $(5, 25] \rightarrow \text{MODERATE}$
- $(25, 50] \rightarrow \text{STRONG}$
- $(50, \infty) \rightarrow \text{EXTREME}$

Divisão dos dados

Utilize a mesma estratégia de divisão treino/teste adotada no Trabalho 1 para o arquivo `A652.pickle`: separe os dados cronologicamente, reservando os últimos 20% das amostras para teste e utilizando os 80% iniciais para treino. Não aplique embaralhamento (*shuffle*), de modo a preservar a ordem temporal das observações.

Tarefa

1. Implemente um classificador ordinal multiclasse com base na abordagem do artigo, conforme descrito acima.
2. Use o algoritmo `GradientBoostingClassifier` como classificador de base.
3. Implemente também um segundo modelo, também com `GradientBoostingClassifier`, mas tratando o problema como uma classificação multiclasse convencional, isto é, **sem explorar explicitamente a ordem entre as classes**.
4. Avalie ambos os modelos sobre seus respectivos conjuntos de teste, apresentando:
 - matriz de confusão;
 - `classification_report` do Scikit-Learn.
5. Faça uma análise comparativa entre os dois modelos. Sua análise deve comentar não apenas o desempenho geral, mas também a natureza dos erros cometidos. Em particular, discuta se os erros tendem a ocorrer entre classes vizinhas ou entre classes mais distantes na ordem ordinal.

3 SHAP Values (2 pts)

Considere novamente o contexto do problema meteorológico anterior. Considere também os arquivos:

- `A652_train.parquet.gzip`
- `A652_val.parquet.gzip`
- `A652_test.parquet.gzip`

Nesses arquivos, 652 representa o identificador da estação meteorológica. Os nomes das colunas permitem interpretar o significado de cada atributo.

Neste item, considere o seguinte problema de classificação binária:

EXTREME vs. não-EXTREME

Inicialmente, una os conjuntos de treino e validação em um único conjunto, que será chamado de D . Em seguida, treine um modelo `GradientBoostingClassifier` sobre D . Depois, apresente uma análise de explicabilidade sobre o comportamento desse modelo no conjunto de teste, utilizando a biblioteca SHAP¹.

Tarefa

Sua análise deve incluir, no mínimo:

1. uma análise **local**, explicando a predição de pelo menos uma instância específica. Indique os valores das *features* dessa instância e discuta por que as contribuições SHAP fazem sentido à luz do contexto meteorológico;
2. uma análise **global**, indicando quais *features* mais influenciam o comportamento geral do modelo;
3. uma discussão específica sobre a classe **EXTREME**, comentando quais atributos parecem mais relevantes para esse tipo de evento e em que direção (positiva ou negativa) eles influenciam a predição;
4. pelo menos uma visualização que ajude a entender como a variação de uma *feature* afeta as predições ou contribuições SHAP (por exemplo, um *dependence plot* ou um gráfico de efeito parcial baseado em SHAP);
5. uma interpretação dos resultados que vá além da simples descrição dos gráficos: levante hipóteses sobre os padrões observados, relacione-os ao domínio meteorológico e, quando pertinente, aponte limitações ou comportamentos inesperados do modelo.

Você pode usar, entre outras, perguntas como as seguintes para orientar sua análise:

- Qual a importância de cada *feature* para uma predição específica?
- Como uma *feature* específica impacta a predição em geral?
- Quais instâncias da classe **EXTREME** são mais influenciadas por uma determinada *feature*?
- Quais *features* apresentam contribuições mais consistentes ou mais variáveis?

¹<https://shap.readthedocs.io/en/latest/>

4 Redução de dimensionalidade (2 pts)

Considere novamente o problema de classificação ordinal multiclasse apresentado no item 2, utilizando os mesmos dados do arquivo `A652.pickle` e a mesma divisão treino/teste descrita naquela seção. Neste item, você realizará um experimento com PCA.

A estratégia de *three-way holdout* consiste em dividir os dados em três partes disjuntas: treino, validação e teste. O conjunto de treino é usado para ajustar o modelo; o conjunto de validação, para selecionar hiperparâmetros (neste caso, o número de componentes k); e o conjunto de teste, reservado exclusivamente para a avaliação final. Nenhuma informação do conjunto de teste deve influenciar as decisões tomadas durante o desenvolvimento do modelo.

Chame o conjunto original de D_1 . Use a estratégia de *three-way holdout* para escolher o melhor número de componentes principais, k . Em seguida, aplique PCA com esse valor de k , obtendo um novo conjunto transformado, chamado D_2 .

Tarefa

1. Padronize adequadamente os atributos numéricos antes de aplicar PCA.
2. Escolha o melhor valor de k usando apenas os dados de treino e validação. Descreva o critério adotado para essa escolha (por exemplo, variância explicada acumulada ou desempenho de classificação na validação).
3. Ajuste dois modelos de classificação com `GradientBoostingClassifier`:
 - um usando os dados originais (D_1);
 - outro usando os dados transformados por PCA (D_2).
4. Avalie os dois modelos no conjunto de teste.
5. Apresente uma análise comparativa entre esses dois modelos, discutindo:
 - desempenho preditivo;
 - possível perda ou ganho de informação com PCA;
 - eventual vantagem ou desvantagem do uso de redução de dimensionalidade neste problema.

5 Predição Conforme (2 pts)

Considere novamente o conjunto de dados `diamonds`.

Neste item, você deve usar uma técnica de *conformal prediction* para produzir **intervalos de predição** para exemplos do conjunto de teste em um problema de regressão.

Tarefa

1. Separe os dados em, no mínimo, três partes: treino, calibração e teste.
2. Treine um modelo de regressão no conjunto de treino. Recomenda-se o uso de da classe `sklearn.ensemble.GradientBoostingRegressor` como modelo base, por oferecer bom equilíbrio entre desempenho e interpretabilidade no contexto deste trabalho. Outros modelos são aceitos, desde que a escolha seja justificada.

3. Use o conjunto de calibração para construir intervalos de predição conformes com nível nominal de cobertura de 90%.
4. Aplique o método ao conjunto de teste e reporte:
 - a cobertura empírica observada;
 - a largura média dos intervalos de predição.
5. Selecione, no conjunto de teste, ao menos:
 - um exemplo com intervalo entre os mais estreitos;
 - um exemplo com intervalo entre os mais largos.
6. Para esses exemplos, apresente uma análise interpretativa, discutindo por que o modelo pode estar mais ou menos incerto nesses casos.